От ноутбука до multi-GPU

Инфраструктура и софт для локального запуска LLM

Практический алгоритм выбора инструментов для локального запуска LLM (август 2026)

+ Что запускать, на чём, сколько стоит и как обслуживать

А зачем?

Где уже используется AI?

AI в 2026 году вышел далеко за пределы чата. Сценарии, которые уже работают:

- **Код** — генерация, ревью, тесты
- **Текст и документы** — чаты, ИИ-поиск и поиск по документации
- **Агенты** — автоматизация рабочих задач
- **Транскрибация и голос** — Whisper, голосовые ассистенты
- **Медиа** — фото и видео

Кто использует AI во всех сценариях? Ежедневно?

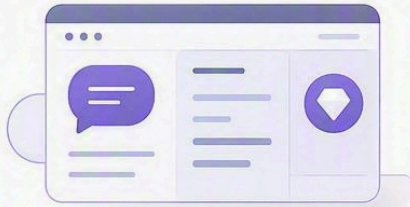
Варианты оплаты LLM-моделей

Почему я рассказываю про локальный запуск

1. Подписка

$0–$200 / мес

ChatGPT и аналоги

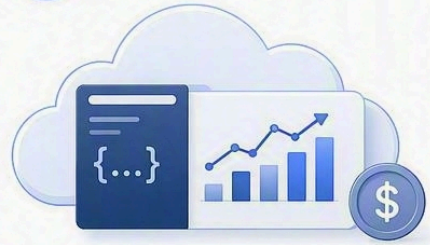


- Готовый UI, голос, агенты, Deep Research
- Фиксированная цена при умеренном использовании
- Динамические лимиты и 429
- Риски утечки данных, сложности оплаты из РФ

2. Models API

~$2–$30 / 1M токенов

Оплата за токены

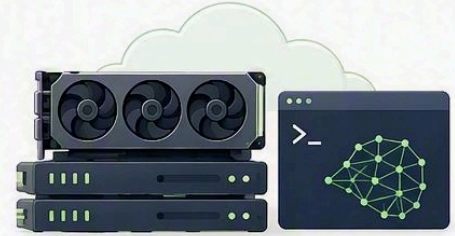


- Pay-as-you-go: платите только за использованное
- Полный контекст, автоматизация, агенты, batch
- Быстро дорожает при активном чате / агентах
- Те же риски данных и сложности оплаты из РФ

3. Аренда GPU

~$0.1–$4 / час

GPU-as-a-Service
для open-weight моделей



- Любая open-weight модель и квантизация
- Нет утечки данных к OpenAI / Anthropic
- Нужно самому поднимать стек и DevOps
- Переменное качество и сетевые задержки

Ключевой вывод

Каждый вариант имеет свои плюсы и минусы.
Локальный запуск LLM даёт максимальный контроль, приватность и предсказуемую стоимость при высокой нагрузке.



Контроль данных

Предсказуемая стоимость

Нет скрытых лимитов

Лучше для РФ


SHUT UP AND
TAKE MY MONEY!

Риски регуляторики и ограничений

Доступ к внешним облачным моделям находится под двойным давлением:

🇷🇺 Внутренние ограничения (РФ, 2026)

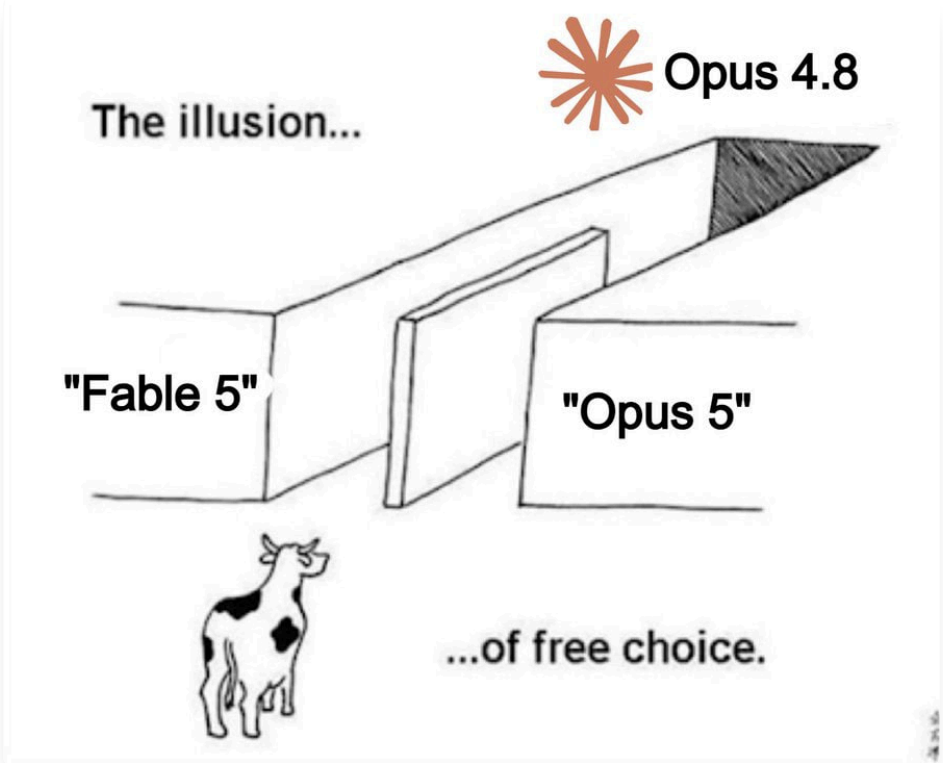
- **Полномочия на запрет:** закон марта 2026 расширил права регуляторов по ограничению и блокировке зарубежных AI-инструментов.
- **Безопасность данных:** требования по КИИ, ФЗ-152 и защите коммерческой тайны делают внешний cloud-инференс юридически рискованным.
- **Риск непрерывности:** вероятность внезапного отключения рабочих сервисов и инструментов разработки.

🌏 Внешние барьеры (Пекин и Запад)

- **Лимиты из Пекина:** обсуждение мер по ограничению трансграничного доступа к передовым китайским AI-моделям (Qwen, Kimi, DeepSeek).
- **Санкционные фильтры:** блокировки аккаунтов, карт и корпоративных подписок со стороны западных провайдеров.
- **Технологическая автономия:** зависимость от внешнего API ставит бизнес под удар геополитики.

Вывод: Доверять критические процессы чужому облаку нельзя. Локальный запуск open-weight моделей — единственный способ гарантировать бесперебойность.

Советские стандарты качества



Ещё одна причина запускать LLM локально

Abliterated (uncensored) open-weight модели и LoRA-модели

Abliterated (uncensored) open-weight модели

Модели без корпоративных safety-фильтров

1. Находим refusal direction
   Контрастные промпты (harmful vs harmless)
2. Удаляем (ортогонализуем) refusal direction
   Из весов модели (attention + MLP)
3. Получаем модель, которая отвечает прямо и без отказов

Быстро и эффективно

- Без большого дообучения
- Сохраняет знания и reasoning

Применяется для:

- Red-teaming и исследования
- Creative / roleplay / NSFW
- Независимость от провайдеров

Популярные базы 2026:
Qwen3.6/3.8 • Gemma 4 • Llama 3.x • GLM 5.1 • DeepSeek-дистилляты и др.

LoRA-модели

Лёгкая кастомизация под ваши задачи

Как создаётся LoRA-модель

1. Базовая модель (заморожена)
2. Обучаем LoRA-адаптер (0.1–1% параметров)
   A × B
3. Адаптер используется при инференсе
4. Можно переключать и комбинировать адаптеры
5. Можно смержить (merge) в базовые веса

Что даёт LoRA

- Нужно меньше VRAM и времени
- Несколько адаптеров и переключение
- Доменные модели, uncensored версии, специализация
- Легко распространять (адаптеры весят МБ-ГБ, а не десятки ГБ)

Варианты 2026
LoRA (16-bit)
QLoRA (4-bit + LoRA)
DoRA • LoRA+ • SDFT

Инструменты:
Unsloth • Axolotl • TRL
Hugging Face PEFT
MLX-LoRA и др.

Почему это важно при локальном запуске

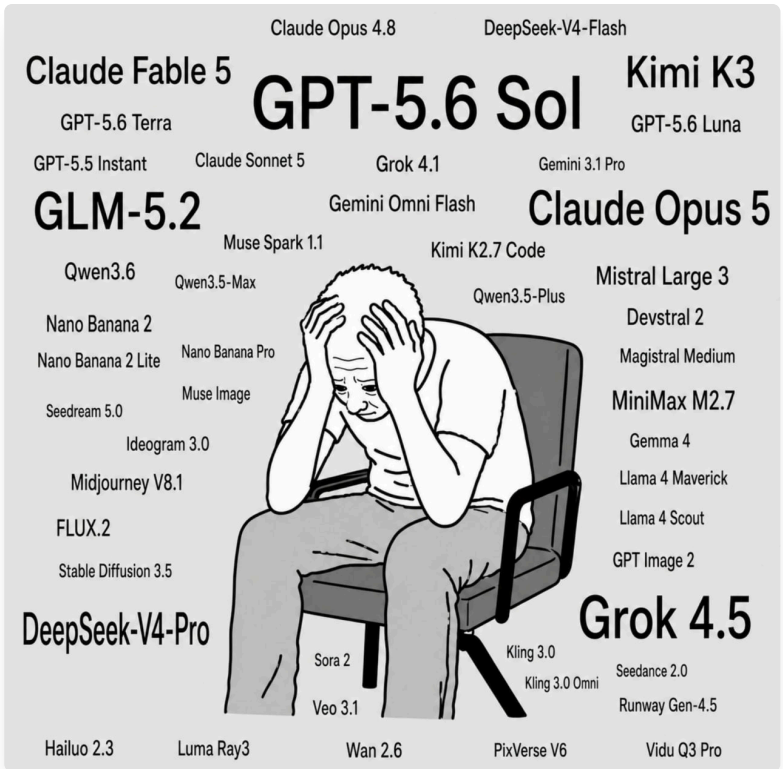
- Полный контроль над отказами модели
- Свобода для исследований и red-teaming
- Creative, roleplay, NSFW и другой uncensored контент
- Domain-адаптация без цензуры и под ваши данные
- Независимость от политики провайдеров

Зачем локально?

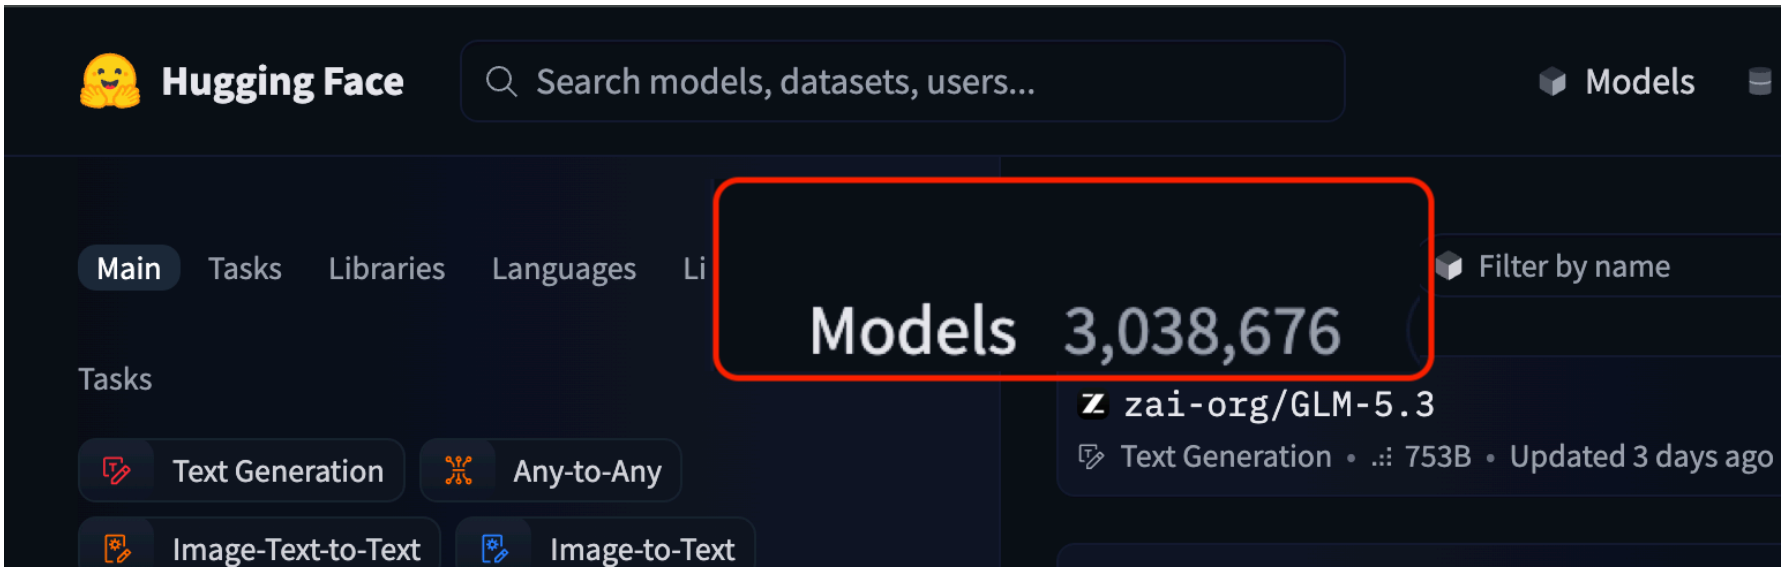
1. **Контроль**
   - Версия модели и квантизация
   - Без сюрпризов от провайдера
2. **Безопасность и закон**
   - ФЗ-152, КИИ, коммерческая тайна. Утечка = риск
3. **Автономность и доступность**
   - Изоляция
   - Без лимитов
   - Без риска блокировки
4. **Кастомизация**
   - Дообучение и модель под задачу

Выбор модели

Трудности выбора модели



Сколько всего моделей на Hugging Face?



Классификация и особенности LLM для локального запуска

1 Размер модели (по параметрам)

Класс	Диапазон параметров	Активные параметров*	Типичные сценарии	VRAM (Q4_K_M)
Tiny	≤ 4B	≤ 2–3B	on-device, IoT, простые задачи	< 4–8 ГБ
Small	4B – 40B	~3B – 35B	агенты, кодинг, RAG, повседневные IT-задачи	8 – 24+ ГБ
Medium	40B – 150B	~20B – 80B	сложная логика, reasoning, продвинутый кодинг, multi-turn агенты	24 – 80+ ГБ
Large	> 150B	~20B – 50B+	замена API, высокий параллелизм, длинный контекст	128+ ГБ (multi-GPU)

* Для MoE — активные параметры за токен.

2 Архитектура

Dense
Все параметры активны для каждого токена

MoE
Только часть экспертов активна за токен

Hybrid
Комбинация dense и MoE

3 Назначение

General
Универсальные задачи

Coding
Программирование и DevOps

Reasoning
Логика и сложные рассуждения

Multimodal
Текст, изображение, аудио, видео

Domain-specific
Специализированные области

4 Training origin и post-training

GPPT general-purpose
Обучены на широких данных

→ **DSPT** domain-specific
Обучены на узкоспециализированных данных

→ Post-training:

- **SFT** Supervised Fine-Tuning
- **RL** Reinforcement Learning
- **Distill** Knowledge Distillation

Комбинирование методов даёт лучший результат под конкретные задачи.

5 Модальность

- Текст
- Изображение
- Аудио
- Видео
- 3D/Другие
- Мультимодальные модели

6 Квантизация

Q4_K_M

- «Золотой стандарт» для локального запуска
- Сохраняет ~90–95% качества (vs FP16/BF16)
- Сильно снижает требования к VRAM
- Оптимальный баланс качество / размер / скорость

Экономия VRAM (пример)
Модель 70B

FP16	~140 ГБ
Q8	~70 ГБ
Q4_K_M	~40 ГБ

7 Контекст и требования к VRAM

Длина контекста

4K – 8K	базовые задачи
16K – 32K	повседневные сценарии
64K – 128K	RAG, кодовые базы
200K+	long context, research

VRAM и конфигурации

< 8 ГБ	Tiny / Small (edge, ноутбуки)
16 – 32 ГБ	Small / Medium (1× GPU)
80+ ГБ	Medium / Large (1–2× GPU)
128+ ГБ	Large (multi-GPU)

Границы классов не строгие и зависят от архитектуры, квантизации и реальных сценариев использования.

Выбор модели = размер + задача + железо + контекст + квантизация.

Где смотреть рейтинги моделей?

При выборе модели для реальных задач стоит опираться на независимые лидерборды:

arena.ai

Слепые A/B-тесты (LMSYS Chatbot Arena). Специализированный лидерборд для webdev и fullstack-разработки.

llm-stats.com

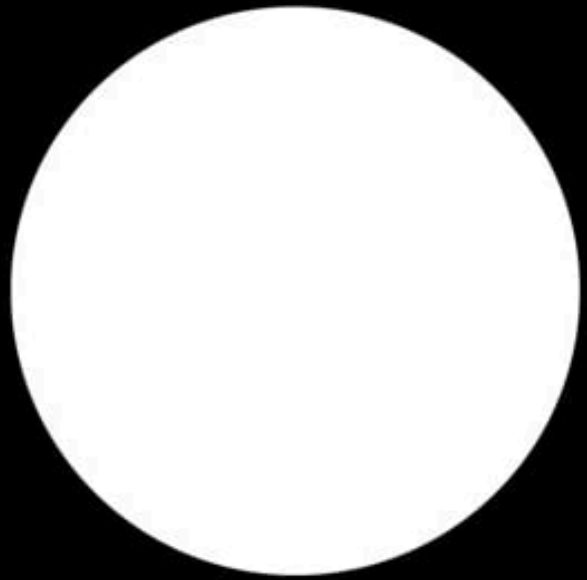
Сводная статистика и актуальный рейтинг лучших моделей для написания и рефакторинга кода.

artificialanalysis.ai

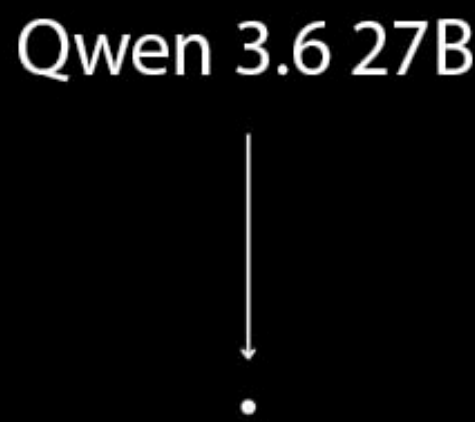
Независимый бенчмарк качества (intelligence breakdown), скорости инференса (токены/сек) и стоимости.

На что обращать внимание:

- **Coding & Agentic benchmarks:** оценивайте тесты на реальном коде, а не синтетические метрики.
- **Соотношение качество / размер:** для локального запуска критичен баланс VRAM и скорости.



74.9 Swe-Bench Verified
GPQA Diamond 85.7
MMMU 84.2



77.2 Swe-Bench Verified
GPQA Diamond 87.8
MMMU 82.9

Софт

Софтверный стек для локального запуска LLM

Инструменты и где их лучше использовать

Ollama	**Быстрый старт** для разработчика
LM Studio	**Удобный GUI** и сравнение моделей
llama.cpp	**Максимальный контроль** и портативность
MLX (+ mlx-lm)	**Максимальная скорость** на Apple Silicon
vLLM	**High concurrency** для production
SGLang	**Agentic & prefix-heavy** RAG, structured output, MoE

Выбор по сценарию

Ноутбук / один разработчик
Ollama, LM Studio или llama.cpp

Небольшой сервер / команда
Ollama, LM Studio
При росте нагрузки — vLLM или SGLang

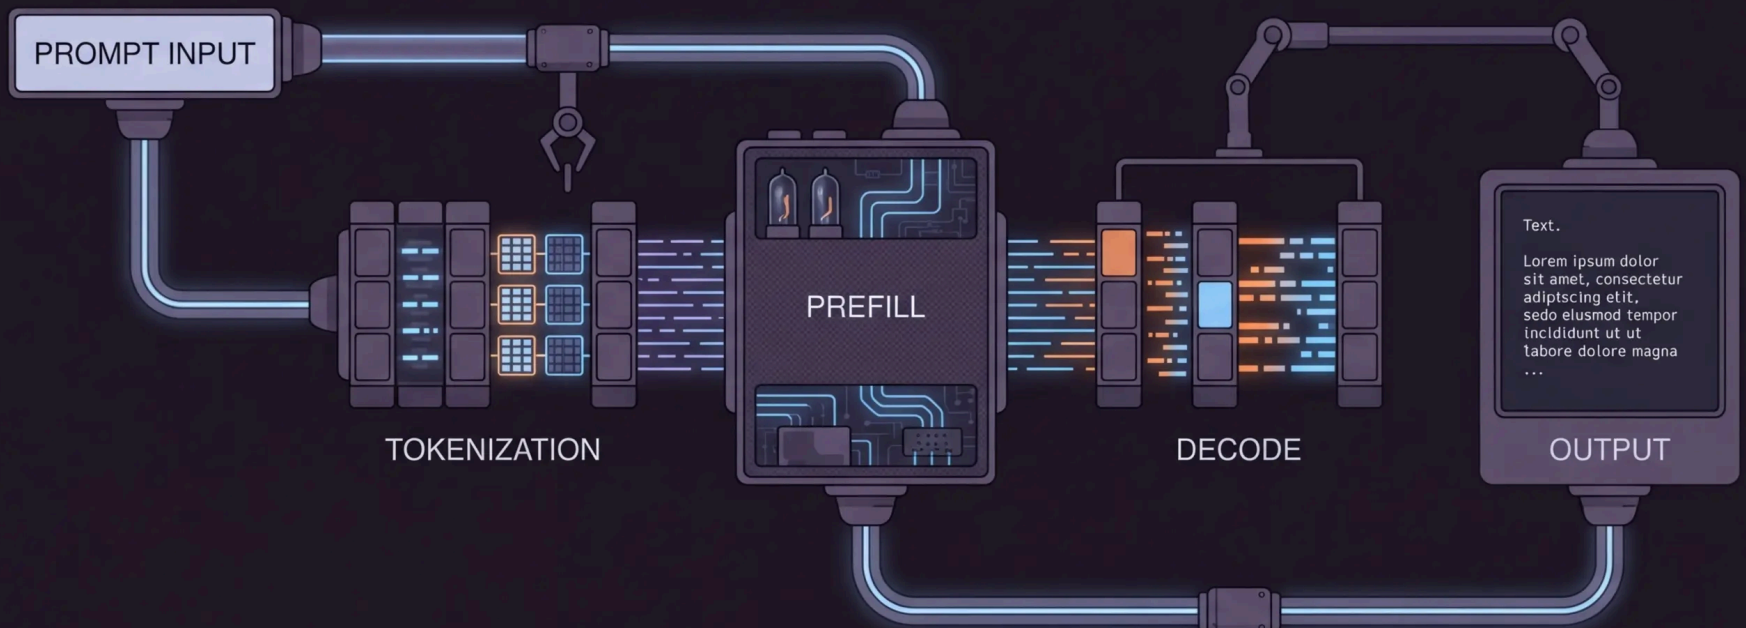
Production / multi-user
vLLM — общий случай
SGLang — agentic, prefix-heavy, MoE, structured output

Apple Silicon (Mac)
MLX через Ollama / LM Studio — максимум скорости

- OpenAI-совместимые API у всех серверов
- Легко разворачиваются в Docker
- Выбор по задачам: single-user vs multi-user
- Широкая совместимость с экосистемой

Инференс

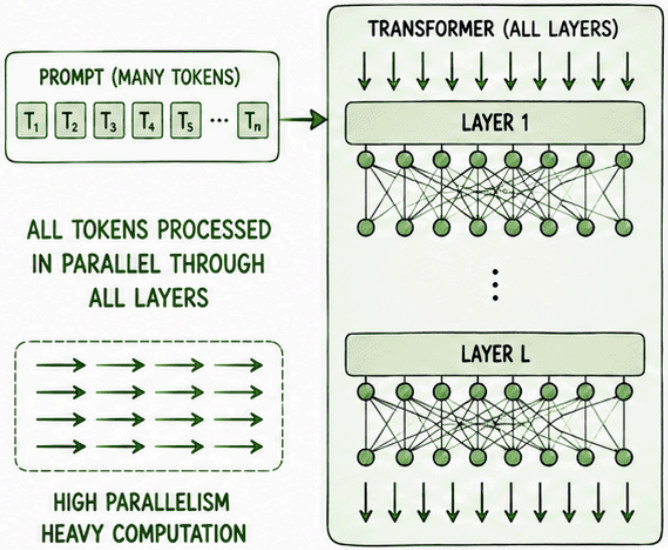
LLM INFERENCE



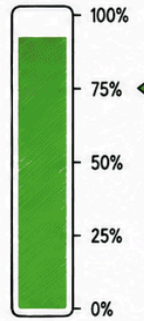
PREFILL VS DECODE

PREFILL

PROCESS THE ENTIRE PROMPT AT ONCE



GPU UTILIZATION



NEAR MAX

MAXIMIZE FLOPS

HIGH PARALLEL WORKLOAD

MORE TOKENS = MORE WORK

GPU CORES FULLY BUSY

COMPUTE-BOUND

TTFT



TIME TO FIRST TOKEN

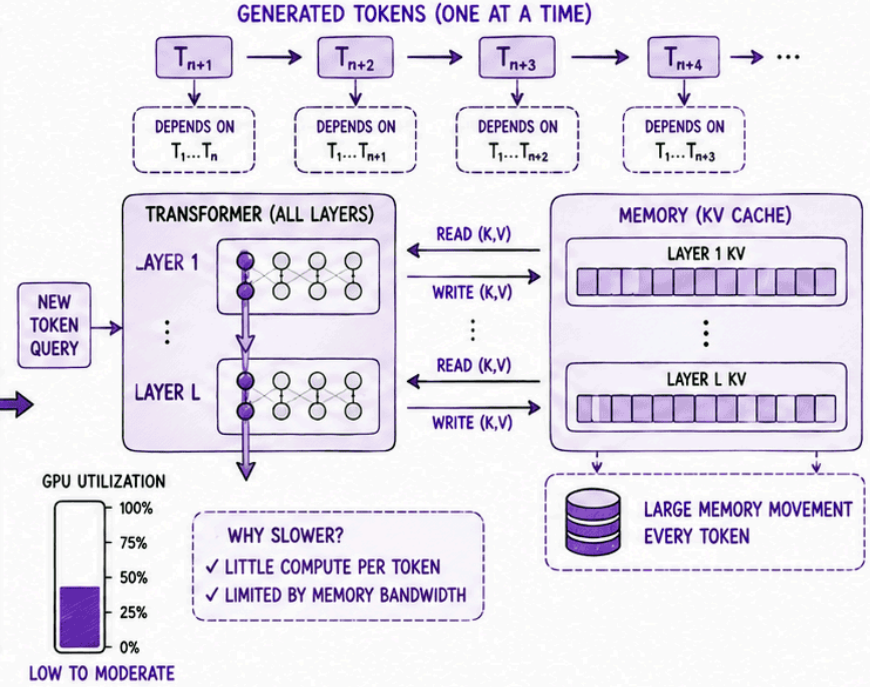
TOKENS/SEC



STEADY-STATE THROUGHPUT

DECODE

GENERATE TOKENS ONE-BY-ONE



GPU UTILIZATION

LOW TO MODERATE

WHY SLOWER?
- ✓ LITTLE COMPUTE PER TOKEN
- ✓ LIMITED BY MEMORY BANDWIDTH

FREQUENT KV READS/WRITES

HIGH DATA MOVEMENT

MEMORY BANDWIDTH IS THE LIMIT

GPU OFTEN WAITING

MEMORY-BANDWIDTH-BOUND

Железо

4 ценовые категории

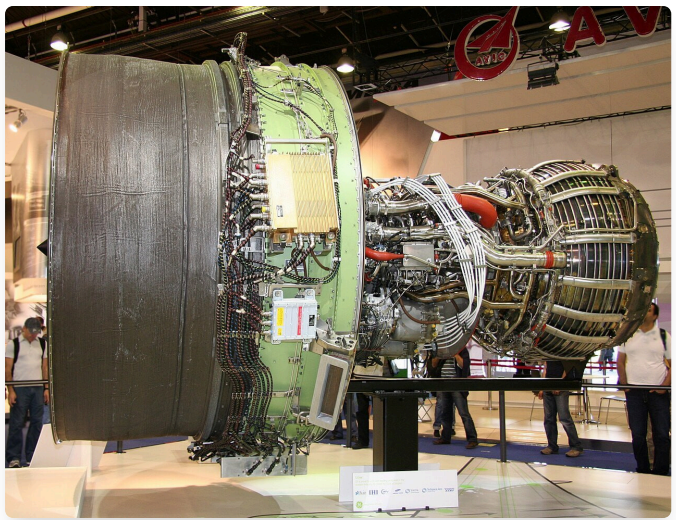
1. Ультрабюджет (до 100 тыс. ₽)
2. Народный (100–200 тыс. ₽)
3. Рабочая станция (200–600 тыс. ₽)
4. Enterprise (от 600 тыс. ₽)

Сравнение платформ для инференса (2026)

Параметр	NVIDIA RTX 4090	Apple Mac Mini M5 Pro	AMD Ryzen AI Halo	NVIDIA DGX Spark
Price (USD)	**$1,599**	**$1,699**	**$3,999**	**$4,699**
Chip / Arch	Ada Lovelace	M5 Pro	Ryzen AI Max+ 395	GB10 Grace Blackwell
Memory / Bandwidth	**24GB GDDR6X** / 1010 GB/s	**24–64GB** / 307 GB/s	**128GB LPDDR5X** / 256 GB/s	**128GB LPDDR5X** / 273 GB/s
Token gen (Llama3 8B)	**~105 tok/s**	~45 tok/s	~45 tok/s	**~55 tok/s**
Token gen (gpt-oss 120B)	**No Fit (мало VRAM)**	**No Fit (<120GB)**	**~34 tok/s**	**~39 tok/s**
Latency (TTFT)	**~35 мс**	~120 мс	~150 мс	~70 мс
Software stack	CUDA / vLLM / SGLang	Apple MLX / Ollama	ROCm / Vulkan / llama.cpp	CUDA / vLLM / TensorRT-LLM
TDP (Потребление)	**450W**	**145W**	**140W**	240W

💡 *RTX 4090 — лидер по скорости и задержкам на моделях до 32B, но для 70B–120B+ требуются системы с объединенной памятью от 128 ГБ (AMD Halo, DGX Spark).*

Почему не серверные GPU?







80 000 ₽

RTX 3090 Palit GamingPro 24Gb (Скупка,trade-IN)

В наличии: несколько



Скидка на доставку

126 462 ₽ + 600 Б

до 100% кешбэк от Альфа-Банка

Apple Mac Studio M1 Max 32/512



270 000 ₽

Beelink gtr9 pro ai max 395 128gb (strix halo)

В наличии: несколько



280 600 ₽

Apple Mac Studio (M4 Max, 2025) 128 гб, 2 тб SSD

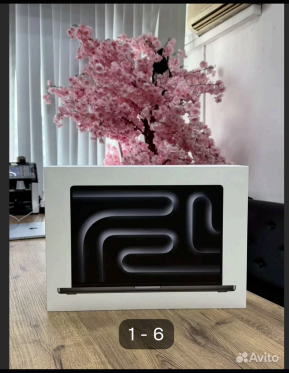


495 000 ₽

До 300 000 ₽ взаймы на что угодно

Суперкомпьютер nvidia DGX Spark в наличии

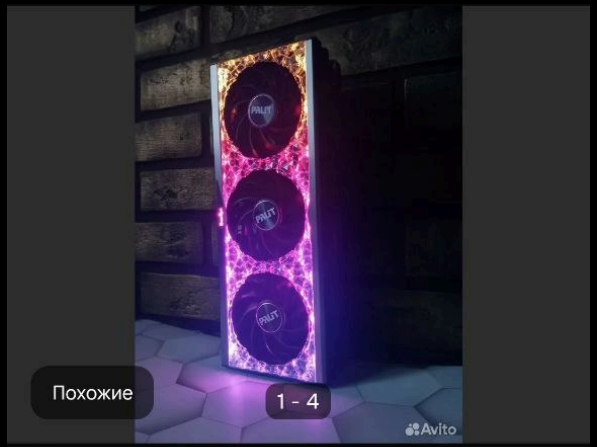
В наличии: несколько



669 999 ₽

До 300 000 ₽ взаймы на что угодно

MacBook Pro 16 M5 Max 128Gb/2Tb nano



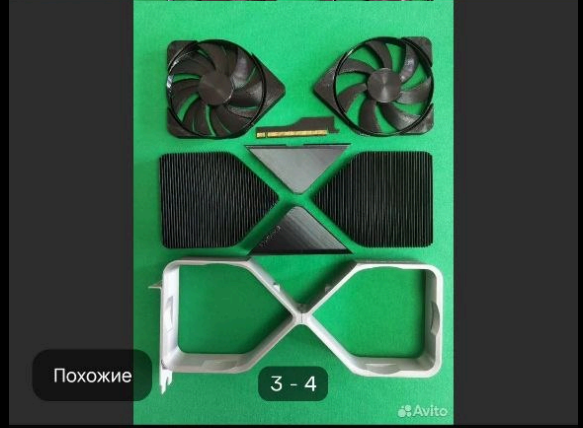
1 889 ₽

RTX 4090 Светильник



2 865 ₽

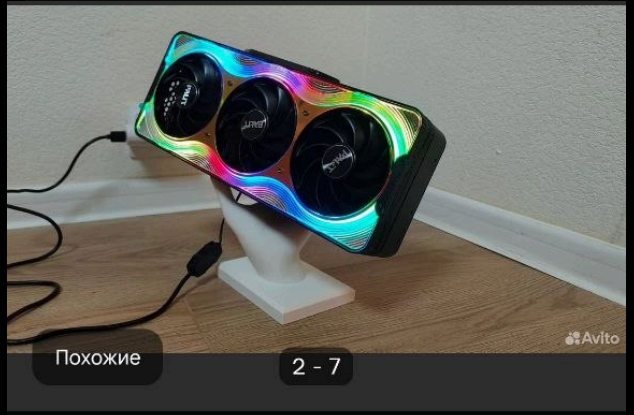
Коробка от rtx 5090



1 289 ₽

Муляж RTX 5090

В наличии: несколько



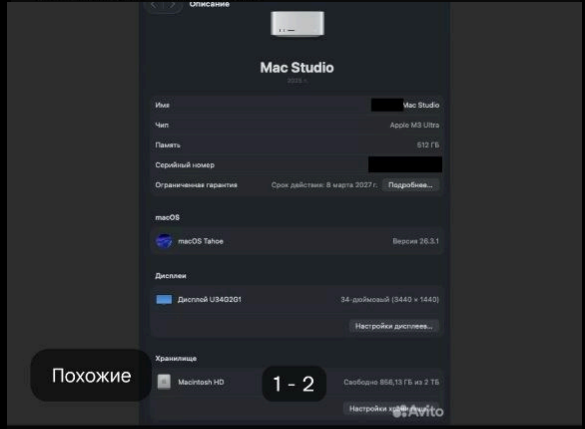
2 984 ₽

Декор rtx 5090 Palit



849 990 ₽

Видеокарта asus GeForce RTX 5090 32768Mb, ROG Astral OC 32 Gb #400871



2 499 000 ₽

Mac studio m3 ultra 512gb 32/80

Юнит-экономика

Расчёт стоимости 1M токенов (On-Premise)

1. Базовая формула

$$\text{Cost}_{1\text{M}} = \frac{\text{GPU_hour_price}}{\text{TPS}_{\text{peak}} \times U \times 3600} \times 10^6$$

где U — утилизация (доля отданных токенов от пика), $\text{TPS}_{\text{eff}} = \text{TPS}_{\text{peak}} \times U$.

2. Стоимость GPU-часа (CAPEX)

$$\text{GPU_hour} = \frac{\text{CAPEX}}{\text{Life}_{\text{hours}}} + P_{\text{kW}} \times \text{Tariff}$$

- **CAPEX:** 400 000 руб. за сервер RTX 4090 (24 ГБ).
- **Амортизация (2 года = 17 520 ч):** $400\,000 / 17\,520 = 22.83$ **руб./ч**.
- **Электроэнергия (TDP 450 Вт, 8 руб./кВт·ч):** $0.45\ \text{кВт} \times 8\ \text{руб.} = 3.60$ **руб./ч**.
- **Полная стоимость часа:** $22.83 + 3.60 = 26.43$ **руб./час**.

3. Расчёт для RTX 4090 ($\text{TPS}_{\text{peak}} = 45\ \text{tok/s}$)

Высокая нагрузка ($U = 50\%$): **~32.6 ₽ / 1M токенов**

$$\frac{26.43}{45 \times 0.50 \times 3600} \times 10^6 \approx 32.63\ \text{руб.}$$

Офисный сценарий ($U = 10\%$): **~163.1 ₽ / 1M токенов**

$$\frac{26.43}{45 \times 0.10 \times 3600} \times 10^6 \approx 163.15\ \text{руб.}$$

Редкие запросы ($U = 2\%$): **~815.7 ₽ / 1M токенов**

Аренда GPU: стоимость 1M токенов (Dedicated)

1. Параметры тарифа Selectel

- **Конфигурация:** Сервер с 1× RTX 4090 24 ГБ.
- **Ежемесячная стоимость:** 62 309 руб. / месяц.
- **Количество часов в месяце:** $30 \times 24 = 720$ часов.

Стоимость 1 часа аренды:

$$\text{GPU_hour} = \frac{62\,309 \text{ руб.}}{720 \text{ ч}} \approx \mathbf{86.54} \text{ руб./час}$$

(включает электричество, стойку, канал, базовую поддержку)

2. Входные данные для инференса

- Модель: **Qwen3.8-27B**.
- Пиковая скорость: $\text{TPS}_{\text{peak}} = 45$ tok/s.
- Реалистичная утилизация: $U = 10\%$.

3. Расчёт стоимости при $U = 10\%$

$$\text{Cost}_{1\text{M}} = \frac{\text{GPU_hour}}{\text{TPS}_{\text{peak}} \times U \times 3600} \times 10^6$$

Подставляем значения:

$$\text{Cost}_{1\text{M}} = \frac{86.54}{45 \times 0.10 \times 3600} \times 10^6 \approx \mathbf{534.2} \text{ руб.}$$

~534 ₽ за 1 миллион токенов

Сравнение при разной утилизации:

Нагрузка 50%	Нагрузка 10%	Нагрузка 2%
~106.8 ₽	~534.2 ₽	~2 671 ₽

📌 *Облачный dedicated GPU снимает CAPEX, но час в ~3.3 раза дороже своего железа.*

Сравнение стоимости 1M токенов

ВАРИАНТ 1

Своё железо (CAPEX)

- **Сервер:** 1× RTX 4090 (400k ₽)
- **Час работы:** ~26.4 ₽/час

- При $U = 50\%$: **~33 ₽**
- При $U = 10\%$: **~163 ₽**
- При $U = 2\%$: **~816 ₽**

✅ Мин. цена при нагрузке
⚠️ Нужен начальный бюджет

ВАРИАНТ 2

Selectel (Dedicated)

- **Аренда:** 1× RTX 4090 (62.3k ₽/мес)
- **Час работы:** ~86.5 ₽/час

- При $U = 50\%$: **~107 ₽**
- При $U = 10\%$: **~534 ₽**
- При $U = 2\%$: **~2 671 ₽**

✅ Быстрый старт без покупки
⚠️ Оплата за всё время (24/7)

ВАРИАНТ 3

Cloud.ru (Pay-as-you-go)

- **Модель:** Qwen3 (Models API)
- **Тариф:** 43 ₽ вх. / 173 ₽ вых.

Средневзвешенная смесь ($3:1$ in/out):

$$\text{Cost}_{1\text{M}} = \frac{3 \times 43 + 1 \times 173}{4} \approx \mathbf{75.5}\ \text{руб.}$$

✅ 0 ₽ в моменты простоя
⚠️ Растет линейно с трафиком

Точка безубыточности: Если утилизация ниже ~15–20%, Pay-as-you-go (75–100 ₽/1M) выгоднее аренды GPU в облаке. Но если у вас стабильный поток (U > 30%) — своё железо выигрывает у всех в 2–5 раз (~33 ₽/1M).

Краткие рекомендации

- **Один человек:**
  - Mac (mini) M5 Pro 24+ ГБ + Qwen3.6-35B-A3B + MLX/Ollama
- **Команда / небольшая компания:**
  - 1–2× RTX 4090 24 ГБ + Qwen3.8-27B + vLLM/SGLang
- **Корпоративный контур / десятки-сотни пользователей:**
  - multi-GPU NVIDIA H100 80 ГБ + … + vLLM/SGLang
  - multi-GPU MetaX C550 64 ГБ + … + vLLM/SGLang

Итоги

Итоги

- Локальный LLM — это про **контроль, безопасность и предсказуемость**, а не про «максимальное качество любой ценой».
- В 2026 году открытые модели уже закрывают **80% повседневных IT-задач** (см. `harness`).
- Главное — считать экономику и выбирать стек под реальную нагрузку.

Вопросы?

Гайнанов Руслан
ИТ Холдинг Т1

centicore-devops.gainanov.pro

